# Media (Valoarea Așteptată) a unei Variabile Aleatoare

## 1 Definiția generală a valorii așteptate

**Definiție 1.** *Fie $X$ o variabilă aleatoare discretă cu valori în mulțimea cel mult numărabilă $S = \{x_1, x_2, \dots\}$ și funcție de masă a probabilității $p(x_k) = \mathbb{P}(X = x_k)$.* ***Valoarea așteptată*** *(sau* ***media****) lui $X$ este*

$$\mathbb{E}[X] := \sum_k x_k \, p(x_k),$$

*dacă seria este absolut convergentă, adică $\sum_k |x_k| p(x_k) < \infty$.*

**Definiție 2.** *Fie $X$ o variabilă aleatoare continuă cu densitate $f : \mathbb{R} \to [0, \infty)$.* ***Valoarea așteptată*** *a lui $X$ este*

$$\mathbb{E}[X] := \int_{-\infty}^{\infty} x f(x) \, dx,$$

*dacă integrala Lebesgue $\int_{-\infty}^{\infty} |x| f(x) \, dx$ este finită.*

## 2 Proprietăți fundamentale ale valorii așteptate

**Propoziție 1** (Linearitatea)**.** *Fie $X, Y$ variabile aleatoare cu $\mathbb{E}[|X|] < \infty$, $\mathbb{E}[|Y|] < \infty$ și $a, b \in \mathbb{R}$. Atunci*

$$\mathbb{E}[aX + bY] = a \, \mathbb{E}[X] + b \, \mathbb{E}[Y].$$

*Demonstraţie.* Demonstrăm pentru cazul discret; cazul continuu este analog, cu sume înlocuite de integrale.

Presupunem că $X$ și $Y$ iau valori în mulțimile cel mult numărabile $S_X = \{x_i\}$, $S_Y = \{y_j\}$. Atunci

$$\mathbb{E}[aX + bY] = \sum_{i,j} (a x_i + b y_j) \, \mathbb{P}(X = x_i, Y = y_j).$$

Dezvoltăm:

$$\mathbb{E}[aX + bY] = a \sum_{i,j} x_i \, \mathbb{P}(X = x_i, Y = y_j) + b \sum_{i,j} y_j \, \mathbb{P}(X = x_i, Y = y_j).$$

Observăm că

$$\sum_j \mathbb{P}(X = x_i, Y = y_j) = \mathbb{P}(X = x_i),$$

deci

$$\sum_{i,j} x_i \, \mathbb{P}(X = x_i, Y = y_j) = \sum_i x_i \sum_j \mathbb{P}(X = x_i, Y = y_j) = \sum_i x_i \, \mathbb{P}(X = x_i) = \mathbb{E}[X].$$

Analog,

$$\sum_{i,j} y_j \, \mathbb{P}(X = x_i, Y = y_j) = \sum_j y_j \, \mathbb{P}(Y = y_j) = \mathbb{E}[Y].$$

Prin urmare,

$$\mathbb{E}[aX + bY] = a \, \mathbb{E}[X] + b \, \mathbb{E}[Y].$$

□

**Propoziție 2** (Media unei constante)**.** *Pentru orice constantă $c \in \mathbb{R}$, dacă $X \equiv c$ (adică $X(\omega) = c$ pentru orice $\omega$), atunci*

$$\mathbb{E}[X] = c.$$

*Demonstraţie.* În cazul discret, $X$ ia o singură valoare $c$ cu probabilitate 1:

$$\mathbb{E}[X] = \sum_x x \, \mathbb{P}(X = x) = c \cdot \mathbb{P}(X = c) = c \cdot 1 = c.$$

În cazul continuu, densitatea este concentrată în sens de distribuție la $c$, iar integrala dă același rezultat. □

**Propoziție 3** (Monotonicitate)**.** *Dacă $X \leq Y$ aproape sigur și $\mathbb{E}[X], \mathbb{E}[Y]$ există, atunci*

$$\mathbb{E}[X] \leq \mathbb{E}[Y].$$

*Demonstraţie.* Considerăm variabila $Z = Y - X \geq 0$ aproape sigur. Atunci $\mathbb{E}[Z] \geq 0$ (deoarece integrala/suma unei funcții nenegative este nenegativă). Dar

$$\mathbb{E}[Z] = \mathbb{E}[Y - X] = \mathbb{E}[Y] - \mathbb{E}[X],$$

de unde rezultă $\mathbb{E}[Y] - \mathbb{E}[X] \geq 0$, adică $\mathbb{E}[X] \leq \mathbb{E}[Y]$. □

# 3 Teorema de transport (discretă și continuă)

**Propoziție 4** (Teorema de transport – cazul discret)**.** *Fie $X$ o variabilă aleatoare discretă cu valori în mulțimea cel mult numărabilă $S = \{x_k\}$ și fie $g : S \to \mathbb{R}$ o funcție arbitrară. Dacă seria $\sum_k |g(x_k)| \, \mathbb{P}(X = x_k)$ este convergentă, atunci*

$$\mathbb{E}[\, g(X) \,] = \sum_k g(x_k) \, \mathbb{P}(X = x_k).$$

*Demonstraţie.* Variabila $g(X)$ este discretă și ia valorile $g(x_k)$ cu probabilitățile $\mathbb{P}(X = x_k)$. Aplicăm definiția valorii așteptate pentru variabile discrete. □

**Propoziție 5** (Teorema de transport – cazul continuu)**.** *Fie $X$ o variabilă aleatoare continuă cu densitate $f$ și fie $g : \mathbb{R} \to \mathbb{R}$ o funcție măsurabilă. Dacă integrala Lebesgue $\int_{\mathbb{R}} |g(x)| f(x)\, dx$ este finită, atunci*

$$\mathbb{E}[\, g(X)\,] = \int_{-\infty}^{\infty} g(x)\, f(x)\, dx.$$

*Demonstraţie.* Variabila $g(X)$ are distribuție indusă de $X$ prin aplicația $g$. Prin definiția valorii așteptate pentru variabile continue, integrăm funcția $g(x)$ ponderată cu densitatea lui $X$. □

**Exemplu 1.** *Dacă $g(x) = x^2$, teorema de transport dă formula generală pentru momentul de ordinul al doilea:*

$$\mathbb{E}[X^2] = \begin{cases} \sum_k x_k^2\, \mathbb{P}(X = x_k), & \textit{(discret)} \\ \int_{-\infty}^{\infty} x^2 f(x)\, dx, & \textit{(continuu).} \end{cases}$$

# 4 Mediile distribuțiilor discrete fundamentale

## 4.1 Distribuția Bernoulli

**Definiție 3.** $X \sim \text{Bernoulli}(p)$ *dacă*

$$\mathbb{P}(X = 1) = p, \quad \mathbb{P}(X = 0) = 1 - p.$$

**Propoziție 6.** *Dacă $X \sim \text{Bernoulli}(p)$, atunci*

$$\mathbb{E}[X] = p.$$

*Demonstraţie.* Prin definiție:

$$\mathbb{E}[X] = 0 \cdot \mathbb{P}(X = 0) + 1 \cdot \mathbb{P}(X = 1) = 0 \cdot (1 - p) + 1 \cdot p = p.$$

□

## 4.2 Distribuția polinomială pe o mulțime finită

**Definiție 4.** *Fie $S = \{x_1, \ldots, x_k\}$ și $\mathbb{P}(X = x_i) = p_i$, cu $\sum_{i=1}^{k} p_i = 1$. Spunem că $X$ are distribuție polinomială pe $S$.*

**Propoziție 7.** *Media lui $X$ este*

$$\mathbb{E}[X] = \sum_{i=1}^{k} x_i p_i.$$

*Demonstraţie.* Direct din definiția generală a valorii așteptate pentru variabile discrete. □

## 4.3 Distribuția geometrică

**Definiție 5.** $X \sim \mathrm{Geom}(p)$ *dacă*

$$\mathbb{P}(X = k) = (1-p)^{k-1}p, \quad k = 1, 2, \ldots$$

**Propoziție 8.** *Dacă* $X \sim \mathrm{Geom}(p)$, *atunci*

$$\mathbb{E}[X] = \frac{1}{p}.$$

*Demonstraţie.* Avem

$$\mathbb{E}[X] = \sum_{k=1}^{\infty} k(1-p)^{k-1}p = p\sum_{k=1}^{\infty} kq^{k-1},$$

unde $q = 1 - p$. Știm că pentru $|q| < 1$,

$$\sum_{k=1}^{\infty} kq^{k-1} = \frac{1}{(1-q)^2}.$$

Aceasta se obține derivând seria geometrică $\sum_{k=0}^{\infty} q^k = \frac{1}{1-q}$. Deci

$$\mathbb{E}[X] = p \cdot \frac{1}{(1-q)^2} = p \cdot \frac{1}{p^2} = \frac{1}{p}.$$

□

## 4.4 Distribuția binomială negativă

**Definiție 6.** $X \sim \mathrm{NegBin}(r, p)$ *dacă*

$$\mathbb{P}(X = k) = \binom{k-1}{r-1} p^r (1-p)^{k-r}, \quad k = r, r+1, \ldots$$

**Propoziție 9.** *Dacă* $X \sim \mathrm{NegBin}(r, p)$, *atunci*

$$\mathbb{E}[X] = \frac{r}{p}.$$

*Demonstraţie.* Interpretăm $X$ ca numărul de încercări necesare pentru a obține $r$ succese, unde fiecare încercare este Bernoulli($p$) și încercările sunt independente. Fie $X_i$ numărul de încercări necesare pentru a obține succesul $i$ după succesul $i-1$. Atunci $X_i \sim \mathrm{Geom}(p)$, independente, și

$$X = X_1 + \cdots + X_r.$$

Prin linearitatea valorii așteptate și rezultatul pentru geometrică:

$$\mathbb{E}[X] = \sum_{i=1}^{r} \mathbb{E}[X_i] = r \cdot \frac{1}{p} = \frac{r}{p}.$$

□

## 4.5 Distribuția Poisson

**Definiție 7.** $X \sim \text{Poisson}(\lambda)$ *dacă*

$$\mathbb{P}(X = k) = e^{-\lambda}\frac{\lambda^k}{k!}, \quad k = 0, 1, 2, \ldots$$

**Propoziție 10.** *Dacă* $X \sim \text{Poisson}(\lambda)$, *atunci*

$$\mathbb{E}[X] = \lambda.$$

*Demonstraţie.* Calculăm:

$$\mathbb{E}[X] = \sum_{k=0}^{\infty} k e^{-\lambda}\frac{\lambda^k}{k!} = e^{-\lambda}\sum_{k=1}^{\infty} k\frac{\lambda^k}{k!}.$$

Pentru $k \geq 1$, $k\frac{\lambda^k}{k!} = \lambda\frac{\lambda^{k-1}}{(k-1)!}$, deci

$$\mathbb{E}[X] = e^{-\lambda}\lambda\sum_{k=1}^{\infty}\frac{\lambda^{k-1}}{(k-1)!} = \lambda e^{-\lambda}\sum_{j=0}^{\infty}\frac{\lambda^j}{j!} = \lambda e^{-\lambda}e^{\lambda} = \lambda.$$

□

## 4.6 Distribuția hipergeometrică

**Definiție 8.** $X \sim \text{Hypergeom}(N, M, n)$ *dacă*

$$\mathbb{P}(X = k) = \frac{\binom{M}{k}\binom{N-M}{n-k}}{\binom{N}{n}}, \quad k = 0, 1, \ldots, n,$$

*unde $N$ este mărimea populației, $M$ numărul de "succese" în populație, iar $n$ mărimea eșantionului extras fără înlocuire.*

**Propoziție 11.** *Dacă* $X \sim \text{Hypergeom}(N, M, n)$, *atunci*

$$\mathbb{E}[X] = n\frac{M}{N}.$$

*Demonstraţie.* Considerăm indicatorii $I_i$ pentru fiecare element extras, $i = 1, \ldots, n$: $I_i = 1$ dacă al $i$-lea element extras este succes, 0 altfel. Atunci

$$X = I_1 + \cdots + I_n.$$

Prin linearitate:

$$\mathbb{E}[X] = \sum_{i=1}^{n}\mathbb{E}[I_i].$$

Dar $\mathbb{E}[I_i] = \mathbb{P}(I_i = 1)$ este probabilitatea ca un element extras să fie succes. Deoarece extragerile sunt simetrice, această probabilitate este

$$\mathbb{P}(I_i = 1) = \frac{M}{N}.$$

Deci

$$\mathbb{E}[X] = \sum_{i=1}^{n} \frac{M}{N} = n\frac{M}{N}.$$

□

## 4.7 Distribuția multinomială

**Definiție 9.** $(X_1, \ldots, X_k) \sim \text{Multinomial}(n; p_1, \ldots, p_k)$ *dacă*

$$\mathbb{P}(X_1 = x_1, \ldots, X_k = x_k) = \frac{n!}{x_1! \cdots x_k!} p_1^{x_1} \cdots p_k^{x_k},$$

*unde* $x_1 + \cdots + x_k = n$.

**Propoziție 12.** *Dacă* $(X_1, \ldots, X_k) \sim \text{Multinomial}(n; p_1, \ldots, p_k)$, *atunci*

$$\mathbb{E}[X_i] = np_i, \quad i = 1, \ldots, k.$$

*Demonstraţie.* Interpretăm $X_i$ ca numărul de apariții ale categoriei $i$ în $n$ încercări independente, fiecare încercare având probabilitatea $p_i$ de a fi în categoria $i$. Atunci $X_i$ are distribuție binomială $\text{Bin}(n, p_i)$, iar media unei binomiale este $np_i$. Riguros, putem scrie $X_i = \sum_{j=1}^{n} I_{ij}$, unde $I_{ij}$ este indicatorul că încercarea $j$ a căzut în categoria $i$. Atunci

$$\mathbb{E}[X_i] = \sum_{j=1}^{n} \mathbb{E}[I_{ij}] = \sum_{j=1}^{n} p_i = np_i.$$

□

# 5 Mediile distribuțiilor continue fundamentale

## 5.1 Distribuția uniformă pe un interval

**Definiție 10.** $X \sim \text{Unif}(a, b)$ *dacă*

$$f(x) = \begin{cases} \dfrac{1}{b-a}, & x \in [a, b], \\ 0, & \textit{altfel.} \end{cases}$$

**Propoziție 13.** *Dacă* $X \sim \text{Unif}(a, b)$, *atunci*

$$\mathbb{E}[X] = \frac{a+b}{2}.$$

*Demonstraţie.* Prin definiție:

$$\mathbb{E}[X] = \int_{-\infty}^{\infty} x f(x)\, dx = \int_a^b x \frac{1}{b-a}\, dx = \frac{1}{b-a} \int_a^b x\, dx.$$

Calculăm integrala:

$$\int_a^b x\, dx = \left.\frac{x^2}{2}\right|_a^b = \frac{b^2 - a^2}{2} = \frac{(b-a)(b+a)}{2}.$$

Deci

$$\mathbb{E}[X] = \frac{1}{b-a} \cdot \frac{(b-a)(b+a)}{2} = \frac{a+b}{2}.$$

□

## 5.2 Distribuția exponențială

**Definiție 11.** $X \sim \mathrm{Exp}(\lambda)$ *dacă*

$$f(x) = \begin{cases} \lambda e^{-\lambda x}, & x \geq 0, \\ 0, & x < 0. \end{cases}$$

**Propoziție 14.** *Dacă* $X \sim \mathrm{Exp}(\lambda)$, *atunci*

$$\mathbb{E}[X] = \frac{1}{\lambda}.$$

*Demonstraţie.*

$$\mathbb{E}[X] = \int_0^\infty x\lambda e^{-\lambda x}\, dx.$$

Facem schimbarea de variabilă $t = \lambda x$, $x = t/\lambda$, $dx = dt/\lambda$:

$$\mathbb{E}[X] = \int_0^\infty \frac{t}{\lambda}\lambda e^{-t}\frac{1}{\lambda}\, dt = \frac{1}{\lambda}\int_0^\infty te^{-t}\, dt.$$

Dar

$$\int_0^\infty te^{-t}\, dt = \Gamma(2) = 1!,$$

deci

$$\mathbb{E}[X] = \frac{1}{\lambda}.$$

□

## 5.3 Distribuția Gamma

**Definiție 12.** $X \sim \mathrm{Gamma}(\alpha, \lambda)$ *dacă*

$$f(x) = \begin{cases} \dfrac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x}, & x \geq 0, \\ 0, & x < 0. \end{cases}$$

**Propoziție 15.** *Dacă* $X \sim \mathrm{Gamma}(\alpha, \lambda)$, *atunci*

$$\mathbb{E}[X] = \frac{\alpha}{\lambda}.$$

*Demonstraţie.*

$$\mathbb{E}[X] = \int_0^\infty x \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x}\, dx = \frac{\lambda^\alpha}{\Gamma(\alpha)} \int_0^\infty x^\alpha e^{-\lambda x}\, dx.$$

Schimbăm variabila $t = \lambda x$, $x = t/\lambda$, $dx = dt/\lambda$:

$$\mathbb{E}[X] = \frac{\lambda^\alpha}{\Gamma(\alpha)} \int_0^\infty \left(\frac{t}{\lambda}\right)^\alpha e^{-t} \frac{1}{\lambda}\, dt = \frac{\lambda^\alpha}{\Gamma(\alpha)} \cdot \frac{1}{\lambda^{\alpha+1}} \int_0^\infty t^\alpha e^{-t}\, dt.$$

Dar

$$\int_0^\infty t^\alpha e^{-t}\, dt = \Gamma(\alpha+1) = \alpha\Gamma(\alpha).$$

Deci

$$\mathbb{E}[X] = \frac{1}{\lambda} \cdot \frac{\Gamma(\alpha+1)}{\Gamma(\alpha)} = \frac{1}{\lambda} \cdot \alpha = \frac{\alpha}{\lambda}.$$

□

## 5.4 Distribuția normală

**Definiție 13.** $X \sim \mathcal{N}(\mu, \sigma^2)$ *dacă*

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right).$$

**Propoziție 16.** *Dacă* $X \sim \mathcal{N}(\mu, \sigma^2)$, *atunci*

$$\mathbb{E}[X] = \mu.$$

*Demonstraţie.* Facem schimbarea de variabilă $Z = \frac{X-\mu}{\sigma}$. Atunci $Z \sim \mathcal{N}(0,1)$, iar $X = \mu + \sigma Z$. Prin linearitatea valorii așteptate:

$$\mathbb{E}[X] = \mathbb{E}[\mu + \sigma Z] = \mu + \sigma\mathbb{E}[Z].$$

Rămâne să arătăm că $\mathbb{E}[Z] = 0$ pentru $Z \sim \mathcal{N}(0,1)$. Densitatea lui $Z$ este

$$\varphi(z) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2},$$

care este funcție pară: $\varphi(-z) = \varphi(z)$. Atunci

$$\mathbb{E}[Z] = \int_{-\infty}^\infty z\varphi(z)\, dz.$$

Funcția $z\varphi(z)$ este impară, deci integrala pe $\mathbb{R}$ este 0. Prin urmare $\mathbb{E}[Z] = 0$ și

$$\mathbb{E}[X] = \mu.$$

□

# 6 Legături între distribuții: Exp și Gamma

**Propoziție 17.** *Dacă $X_1, \ldots, X_n$ sunt independente și $X_i \sim \mathrm{Exp}(\lambda)$, atunci*

$$S_n = X_1 + \cdots + X_n \sim \mathrm{Gamma}(n, \lambda),$$

*iar*

$$\mathbb{E}[S_n] = \frac{n}{\lambda}.$$

*Demonstraţie.* Fiecare $X_i$ are distribuție Gamma cu parametri $(\alpha = 1, \lambda)$. Se poate arăta (prin convoluție sau prin transformate Laplace) că suma a două variabile Gamma independente cu același parametru de rată $\lambda$ și forme $\alpha_1, \alpha_2$ este $\mathrm{Gamma}(\alpha_1 + \alpha_2, \lambda)$. Prin inducție, $S_n \sim \mathrm{Gamma}(n, \lambda)$.

Pentru medie, folosim linearitatea:

$$\mathbb{E}[S_n] = \sum_{i=1}^{n} \mathbb{E}[X_i] = n \cdot \frac{1}{\lambda} = \frac{n}{\lambda},$$

în acord cu formula pentru $\mathrm{Gamma}(n, \lambda)$. □