Media (Valoarea Așteptată) a unei Variabile Aleatoare

1 Definiția generală a valorii așteptate

Definiție 1. *Fie X o variabilă aleatoare discretă cu valori în mulțimea cel mult numărabilă $S = \{x_1, x_2, \dots\}$ și funcție de masă a probabilității $p(x_k) = \mathbb{P}(X = x_k)$.* ***Valoarea așteptată*** *(sau* ***media****) lui X este*

$$\mathbb{E}[X] := \sum_k x_k \, p(x_k),$$

dacă seria este absolut convergentă, adică $\sum_k |x_k| p(x_k) < \infty$.

Definiție 2. *Fie X o variabilă aleatoare continuă cu densitate $f : \mathbb{R} \to [0, \infty)$.* ***Valoarea așteptată*** *a lui X este*

$$\mathbb{E}[X] := \int_{-\infty}^{\infty} x f(x) \, dx,$$

dacă integrala Lebesgue $\int_{-\infty}^{\infty} |x| f(x) \, dx$ este finită.

2 Proprietăți fundamentale ale valorii așteptate

Propoziție 1 (Linearitatea)**.** *Fie X, Y variabile aleatoare cu $\mathbb{E}[|X|] < \infty$, $\mathbb{E}[|Y|] < \infty$ și $a, b \in \mathbb{R}$. Atunci*

$$\mathbb{E}[aX + bY] = a \, \mathbb{E}[X] + b \, \mathbb{E}[Y].$$

Demonstraţie. Demonstrăm pentru cazul discret; cazul continuu este analog, cu sume înlocuite de integrale.

Presupunem că X și Y iau valori în mulțimile cel mult numărabile $S_X = \{x_i\}$, $S_Y = \{y_j\}$. Atunci

$$\mathbb{E}[aX + bY] = \sum_{i,j} (a x_i + b y_j) \, \mathbb{P}(X = x_i, Y = y_j).$$

Dezvoltăm:

$$\mathbb{E}[aX + bY] = a \sum_{i,j} x_i \, \mathbb{P}(X = x_i, Y = y_j) + b \sum_{i,j} y_j \, \mathbb{P}(X = x_i, Y = y_j).$$

Observăm că

$$\sum_j \mathbb{P}(X = x_i, Y = y_j) = \mathbb{P}(X = x_i),$$

deci

$$\sum_{i,j} x_i \, \mathbb{P}(X = x_i, Y = y_j) = \sum_i x_i \sum_j \mathbb{P}(X = x_i, Y = y_j) = \sum_i x_i \, \mathbb{P}(X = x_i) = \mathbb{E}[X].$$

Analog,

$$\sum_{i,j} y_j \, \mathbb{P}(X = x_i, Y = y_j) = \sum_j y_j \, \mathbb{P}(Y = y_j) = \mathbb{E}[Y].$$

Prin urmare,

$$\mathbb{E}[aX + bY] = a \, \mathbb{E}[X] + b \, \mathbb{E}[Y].$$

□

Propoziție 2 (Media unei constante)**.** *Pentru orice constantă $c \in \mathbb{R}$, dacă $X \equiv c$ (adică $X(\omega) = c$ pentru orice ω), atunci*

$$\mathbb{E}[X] = c.$$

Demonstraţie. În cazul discret, X ia o singură valoare c cu probabilitate 1:

$$\mathbb{E}[X] = \sum_x x \, \mathbb{P}(X = x) = c \cdot \mathbb{P}(X = c) = c \cdot 1 = c.$$

În cazul continuu, densitatea este concentrată în sens de distribuție la c, iar integrala dă același rezultat. □

Propoziție 3 (Monotonicitate)**.** *Dacă $X \leq Y$ aproape sigur și $\mathbb{E}[X], \mathbb{E}[Y]$ există, atunci*

$$\mathbb{E}[X] \leq \mathbb{E}[Y].$$

Demonstraţie. Considerăm variabila $Z = Y - X \geq 0$ aproape sigur. Atunci $\mathbb{E}[Z] \geq 0$ (deoarece integrala/suma unei funcții nenegative este nenegativă). Dar

$$\mathbb{E}[Z] = \mathbb{E}[Y - X] = \mathbb{E}[Y] - \mathbb{E}[X],$$

de unde rezultă $\mathbb{E}[Y] - \mathbb{E}[X] \geq 0$, adică $\mathbb{E}[X] \leq \mathbb{E}[Y]$. □

3 Mediile distribuțiilor discrete fundamentale

3.1 Distribuția Bernoulli

Definiție 3. $X \sim \text{Bernoulli}(p)$ *dacă*

$$\mathbb{P}(X = 1) = p, \quad \mathbb{P}(X = 0) = 1 - p.$$

Propoziție 4. *Dacă* $X \sim \text{Bernoulli}(p)$, *atunci*

$$\mathbb{E}[X] = p.$$

Demonstraţie. Prin definiție:

$$\mathbb{E}[X] = 0 \cdot \mathbb{P}(X = 0) + 1 \cdot \mathbb{P}(X = 1) = 0 \cdot (1 - p) + 1 \cdot p = p.$$

□

3.2 Distribuția polinomială pe o mulțime finită

Definiție 4. *Fie* $S = \{x_1, \ldots, x_k\}$ *și* $\mathbb{P}(X = x_i) = p_i$, *cu* $\sum_{i=1}^{k} p_i = 1$. *Spunem că* X *are distribuție polinomială pe* S.

Propoziție 5. *Media lui* X *este*

$$\mathbb{E}[X] = \sum_{i=1}^{k} x_i p_i.$$

Demonstraţie. Direct din definiția generală a valorii așteptate pentru variabile discrete. □

3.3 Distribuția geometrică

Definiție 5. $X \sim \text{Geom}(p)$ *dacă*

$$\mathbb{P}(X = k) = (1 - p)^{k-1} p, \quad k = 1, 2, \ldots$$

Propoziție 6. *Dacă* $X \sim \text{Geom}(p)$, *atunci*

$$\mathbb{E}[X] = \frac{1}{p}.$$

Demonstraţie. Avem

$$\mathbb{E}[X] = \sum_{k=1}^{\infty} k(1 - p)^{k-1} p = p \sum_{k=1}^{\infty} k q^{k-1},$$

unde $q = 1 - p$. Știm că pentru $|q| < 1$,

$$\sum_{k=1}^{\infty} k q^{k-1} = \frac{1}{(1 - q)^2}.$$

Aceasta se obține derivând seria geometrică $\sum_{k=0}^{\infty} q^k = \frac{1}{1-q}$. Deci

$$\mathbb{E}[X] = p \cdot \frac{1}{(1 - q)^2} = p \cdot \frac{1}{p^2} = \frac{1}{p}.$$

□

3.4 Distribuția binomială negativă

Definiție 6. $X \sim \mathrm{NegBin}(r, p)$ *dacă*

$$\mathbb{P}(X = k) = \binom{k-1}{r-1} p^r (1-p)^{k-r}, \quad k = r, r+1, \ldots$$

Propoziție 7. *Dacă* $X \sim \mathrm{NegBin}(r, p)$, *atunci*

$$\mathbb{E}[X] = \frac{r}{p}.$$

Demonstraţie. Interpretăm X ca numărul de încercări necesare pentru a obține r succese, unde fiecare încercare este Bernoulli(p) și încercările sunt independente. Fie X_i numărul de încercări necesare pentru a obține succesul i după succesul $i-1$. Atunci $X_i \sim \mathrm{Geom}(p)$, independente, și

$$X = X_1 + \cdots + X_r.$$

Prin linearitatea valorii așteptate și rezultatul pentru geometrică:

$$\mathbb{E}[X] = \sum_{i=1}^{r} \mathbb{E}[X_i] = r \cdot \frac{1}{p} = \frac{r}{p}.$$

□

3.5 Distribuția Poisson

Definiție 7. $X \sim \mathrm{Poisson}(\lambda)$ *dacă*

$$\mathbb{P}(X = k) = e^{-\lambda} \frac{\lambda^k}{k!}, \quad k = 0, 1, 2, \ldots$$

Propoziție 8. *Dacă* $X \sim \mathrm{Poisson}(\lambda)$, *atunci*

$$\mathbb{E}[X] = \lambda.$$

Demonstraţie. Calculăm:

$$\mathbb{E}[X] = \sum_{k=0}^{\infty} k e^{-\lambda} \frac{\lambda^k}{k!} = e^{-\lambda} \sum_{k=1}^{\infty} k \frac{\lambda^k}{k!}.$$

Pentru $k \geq 1$, $k\frac{\lambda^k}{k!} = \lambda \frac{\lambda^{k-1}}{(k-1)!}$, deci

$$\mathbb{E}[X] = e^{-\lambda} \lambda \sum_{k=1}^{\infty} \frac{\lambda^{k-1}}{(k-1)!} = \lambda e^{-\lambda} \sum_{j=0}^{\infty} \frac{\lambda^j}{j!} = \lambda e^{-\lambda} e^{\lambda} = \lambda.$$

□

3.6 Distribuția hipergeometrică

Definiție 8. $X \sim \text{Hypergeom}(N, M, n)$ *dacă*

$$\mathbb{P}(X = k) = \frac{\binom{M}{k}\binom{N-M}{n-k}}{\binom{N}{n}}, \quad k = 0, 1, \ldots, n,$$

unde N este mărimea populației, M numărul de "succese" în populație, iar n mărimea eșantionului extras fără înlocuire.

Propoziție 9. *Dacă $X \sim \text{Hypergeom}(N, M, n)$, atunci*

$$\mathbb{E}[X] = n\frac{M}{N}.$$

Demonstraţie. Considerăm indicatorii I_i pentru fiecare element extras, $i = 1, \ldots, n$: $I_i = 1$ dacă al i-lea element extras este succes, 0 altfel. Atunci

$$X = I_1 + \cdots + I_n.$$

Prin linearitate:

$$\mathbb{E}[X] = \sum_{i=1}^{n} \mathbb{E}[I_i].$$

Dar $\mathbb{E}[I_i] = \mathbb{P}(I_i = 1)$ este probabilitatea ca un element extras să fie succes. Deoarece extragerile sunt simetrice, această probabilitate este

$$\mathbb{P}(I_i = 1) = \frac{M}{N}.$$

Deci

$$\mathbb{E}[X] = \sum_{i=1}^{n} \frac{M}{N} = n\frac{M}{N}.$$

□

3.7 Distribuția multinomială

Definiție 9. $(X_1, \ldots, X_k) \sim \text{Multinomial}(n; p_1, \ldots, p_k)$ *dacă*

$$\mathbb{P}(X_1 = x_1, \ldots, X_k = x_k) = \frac{n!}{x_1! \cdots x_k!} p_1^{x_1} \cdots p_k^{x_k},$$

unde $x_1 + \cdots + x_k = n$.

Propoziție 10. *Dacă $(X_1, \ldots, X_k) \sim \text{Multinomial}(n; p_1, \ldots, p_k)$, atunci*

$$\mathbb{E}[X_i] = np_i, \quad i = 1, \ldots, k.$$

Demonstraţie. Interpretăm X_i ca numărul de apariții ale categoriei i în n încercări independente, fiecare încercare având probabilitatea p_i de a fi în categoria i. Atunci X_i are distribuție binomială $\text{Bin}(n, p_i)$, iar media unei binomiale este np_i. Riguros, putem scrie $X_i = \sum_{j=1}^{n} I_{ij}$, unde I_{ij} este indicatorul că încercarea j a căzut în categoria i. Atunci

$$\mathbb{E}[X_i] = \sum_{j=1}^{n} \mathbb{E}[I_{ij}] = \sum_{j=1}^{n} p_i = np_i.$$

□

4 Mediile distribuțiilor continue fundamentale

4.1 Distribuția uniformă pe un interval

Definiție 10. $X \sim \mathrm{Unif}(a, b)$ *dacă*

$$f(x) = \begin{cases} \dfrac{1}{b-a}, & x \in [a, b], \\ 0, & \textit{altfel.} \end{cases}$$

Propoziție 11. *Dacă* $X \sim \mathrm{Unif}(a, b)$, *atunci*

$$\mathbb{E}[X] = \frac{a+b}{2}.$$

Demonstraţie. Prin definiție:

$$\mathbb{E}[X] = \int_{-\infty}^{\infty} x f(x)\, dx = \int_a^b x \frac{1}{b-a}\, dx = \frac{1}{b-a} \int_a^b x\, dx.$$

Calculăm integrala:

$$\int_a^b x\, dx = \left.\frac{x^2}{2}\right|_a^b = \frac{b^2 - a^2}{2} = \frac{(b-a)(b+a)}{2}.$$

Deci

$$\mathbb{E}[X] = \frac{1}{b-a} \cdot \frac{(b-a)(b+a)}{2} = \frac{a+b}{2}.$$

□

4.2 Distribuția exponențială

Definiție 11. $X \sim \mathrm{Exp}(\lambda)$ *dacă*

$$f(x) = \begin{cases} \lambda e^{-\lambda x}, & x \geq 0, \\ 0, & x < 0. \end{cases}$$

Propoziție 12. *Dacă* $X \sim \mathrm{Exp}(\lambda)$, *atunci*

$$\mathbb{E}[X] = \frac{1}{\lambda}.$$

Demonstraţie.

$$\mathbb{E}[X] = \int_0^\infty x\lambda e^{-\lambda x}\,dx.$$

Facem schimbarea de variabilă $t = \lambda x$, $x = t/\lambda$, $dx = dt/\lambda$:

$$\mathbb{E}[X] = \int_0^\infty \frac{t}{\lambda}\lambda e^{-t}\frac{1}{\lambda}\,dt = \frac{1}{\lambda}\int_0^\infty te^{-t}\,dt.$$

Dar

$$\int_0^\infty te^{-t}\,dt = \Gamma(2) = 1!,$$

deci

$$\mathbb{E}[X] = \frac{1}{\lambda}.$$

□

4.3 Distribuția Gamma

Definiție 12. $X \sim \text{Gamma}(\alpha, \lambda)$ *dacă*

$$f(x) = \begin{cases} \dfrac{\lambda^\alpha}{\Gamma(\alpha)}x^{\alpha-1}e^{-\lambda x}, & x \geq 0, \\ 0, & x < 0. \end{cases}$$

Propoziție 13. *Dacă* $X \sim \text{Gamma}(\alpha, \lambda)$, *atunci*

$$\mathbb{E}[X] = \frac{\alpha}{\lambda}.$$

Demonstraţie.

$$\mathbb{E}[X] = \int_0^\infty x\frac{\lambda^\alpha}{\Gamma(\alpha)}x^{\alpha-1}e^{-\lambda x}\,dx = \frac{\lambda^\alpha}{\Gamma(\alpha)}\int_0^\infty x^\alpha e^{-\lambda x}\,dx.$$

Schimbăm variabila $t = \lambda x$, $x = t/\lambda$, $dx = dt/\lambda$:

$$\mathbb{E}[X] = \frac{\lambda^\alpha}{\Gamma(\alpha)}\int_0^\infty \left(\frac{t}{\lambda}\right)^\alpha e^{-t}\frac{1}{\lambda}\,dt = \frac{\lambda^\alpha}{\Gamma(\alpha)}\cdot\frac{1}{\lambda^{\alpha+1}}\int_0^\infty t^\alpha e^{-t}\,dt.$$

Dar

$$\int_0^\infty t^\alpha e^{-t}\,dt = \Gamma(\alpha+1) = \alpha\Gamma(\alpha).$$

Deci

$$\mathbb{E}[X] = \frac{1}{\lambda}\cdot\frac{\Gamma(\alpha+1)}{\Gamma(\alpha)} = \frac{1}{\lambda}\cdot\alpha = \frac{\alpha}{\lambda}.$$

□

4.4 Distribuția normală

Definiție 13. *$X \sim \mathcal{N}(\mu, \sigma^2)$ dacă*

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right).$$

Propoziție 14. *Dacă $X \sim \mathcal{N}(\mu, \sigma^2)$, atunci*

$$\mathbb{E}[X] = \mu.$$

Demonstraţie. Facem schimbarea de variabilă $Z = \frac{X-\mu}{\sigma}$. Atunci $Z \sim \mathcal{N}(0,1)$, iar $X = \mu + \sigma Z$. Prin linearitatea valorii așteptate:

$$\mathbb{E}[X] = \mathbb{E}[\mu + \sigma Z] = \mu + \sigma\mathbb{E}[Z].$$

Rămâne să arătăm că $\mathbb{E}[Z] = 0$ pentru $Z \sim \mathcal{N}(0,1)$. Densitatea lui Z este

$$\varphi(z) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2},$$

care este funcție pară: $\varphi(-z) = \varphi(z)$. Atunci

$$\mathbb{E}[Z] = \int_{-\infty}^{\infty} z\varphi(z)\, dz.$$

Funcția $z\varphi(z)$ este impară, deci integrala pe $\mathbb{R}$ este 0. Prin urmare $\mathbb{E}[Z] = 0$ și

$$\mathbb{E}[X] = \mu.$$

□

5 Legături între distribuții: Exp și Gamma

Propoziție 15. *Dacă $X_1, \ldots, X_n$ sunt independente și $X_i \sim \mathrm{Exp}(\lambda)$, atunci*

$$S_n = X_1 + \cdots + X_n \sim \mathrm{Gamma}(n, \lambda),$$

iar

$$\mathbb{E}[S_n] = \frac{n}{\lambda}.$$

Demonstraţie. Fiecare X_i are distribuție Gamma cu parametri $(\alpha = 1, \lambda)$. Se poate arăta (prin convoluție sau prin transformate Laplace) că suma a două variabile Gamma independente cu același parametru de rată λ și forme α_1, α_2 este $\mathrm{Gamma}(\alpha_1 + \alpha_2, \lambda)$. Prin inducție, $S_n \sim \mathrm{Gamma}(n, \lambda)$.

Pentru medie, folosim linearitatea:

$$\mathbb{E}[S_n] = \sum_{i=1}^{n} \mathbb{E}[X_i] = n \cdot \frac{1}{\lambda} = \frac{n}{\lambda},$$

în acord cu formula pentru $\mathrm{Gamma}(n, \lambda)$. □